

Metriche di valutazione per il captioning sensoriale

Oltre BLEU: CIDEr, BERTScore, conformità lessicale e CLIPScore

Progetto **AI4FQC** — Project 07: *GRANA Captioning* • Relazione tecnica complementare

In sintesi

Affianchiamo a BLEU sei metriche complementari. Tre risultati emergono dai dati: (1) **BLEU inganna** — una baseline che ripete sempre la stessa frase ottiene il BLEU-1 più alto di tutti; (2) **CIDEr discrimina** i modelli là dove BLEU li appiattisce, e ordina correttamente $m1 < m3 < m6$; (3) **CLIPScore** — l'unica metrica che guarda l'immagine — mostra che i modelli addestrati *non* battono la baseline costante, confermando in modo indipendente che, con encoder congelato, l'immagine non viene davvero sfruttata.

1 Perché non basta BLEU

Nel captioning esistono molti modi corretti di descrivere la stessa immagine, ma il dataset fornisce **un solo riferimento** per immagine (la frase del panelista). Una metrica che confronta parola per parola penalizza le riformulazioni corrette:

Riferimento	<i>“Il formaggio ha pasta compatta con occhiatura rada.”</i>
Predizione	<i>“Il formaggio ha pasta dura con piccola occhiatura.”</i>
Stesso significato, parole diverse. BLEU-4 $\approx 0,1$ (nessuna sequenza di 4 parole condivisa), ma la descrizione è corretta .	

Per questo usiamo sette metriche, divise in tre famiglie:

- **Basate sul testo** (predizione vs riferimento testuale): BLEU-1/4, METEOR, ROUGE-L, CIDEr, BERTScore.
- **Basata sull'immagine** (predizione vs immagine, ignora il riferimento): CLIPScore.
- **Specifica del dominio**: Conformità Vocabolario.

Tutti i numeri provengono da `eval_metrics/metrics_summary.csv`: 43 file di predizioni (4 baseline + 3 modelli), su 7 attributi per-attributo e 3 versioni *global*.

2 Le sette metriche, una per una

2.1 BLEU-1 e BLEU-4

Cosa misura. La precisione degli n -gram: quante sequenze di n parole consecutive della predizione compaiono nel riferimento. BLEU-1 (singole parole) $\rightarrow$ “ho usato le parole giuste?”; BLEU-4 (4

parole) → “ho usato la fraseologia giusta, nell’ordine giusto?”.

Range e lettura. Valore in $[0, 1]$, più alto è meglio. Per questo dominio: BLEU-4 $> 0,4$ ottimo; $0,2-0,4$ discreto; $< 0,15$ scarso.

Risultati. Modelli per-attributo BLEU-4 $\approx 0,30-0,45$; modelli *global* $\approx 0,13$ (crollo netto). *Il tranello*: la baseline `most_frequent` emette *sempre* la stessa caption e ottiene il BLEU-1 più alto di tutti ($0,84-0,90$). BLEU premia la ripetizione del template, non la comprensione.

2.2 METEOR

Cosa misura. Come BLEU-1 ma più indulgente: allinea le parole con **stemming** (*compatto* $\approx$ *compatta*) e **sinonimi**, bilanciando precisione e recall.

Range e lettura. $[0, 1]$; tende a essere più alto di BLEU-4. $> 0,6$ forte; $0,4-0,6$ parziale; $< 0,35$ divergente.

Risultati. Per-attributo $\approx 0,53-0,66$; global $\approx 0,29$. Racconta la stessa storia di BLEU → buon segnale di robustezza.

2.3 ROUGE-L

Cosa misura. La più lunga sottosequenza comune (LCS): parole presenti in entrambe le frasi nello stesso ordine, non necessariamente consecutive. Premia il rispetto dell’ordine generale senza richiedere contiguità.

Range e lettura. $[0, 1]$; tipicamente tra BLEU-4 e METEOR.

Risultati. Per-attributo $\approx 0,50-0,67$; global $\approx 0,30$. Si muove in tandem con METEOR/BLEU.

2.4 CIDEr

Cosa misura. È la metrica pensata *apposta* per il captioning. Usa *n*-gram pesati con **TF-IDF**: i termini rari e informativi (*occhiatura*, *piccante*) valgono molto, quelli comuni (*il*, *ha*) quasi nulla. Risponde a: “il modello azzecca i termini sensoriali **salienti**, o riempie con parole generiche?”.

Range e lettura. ≥ 0 , senza tetto fisso (scala $\times 10$). Va letto **in relazione tra modelli sullo stesso attributo**. Implementazione standalone a *un* riferimento: confrontabile fra i nostri modelli, non con benchmark esterni a riferimenti multipli (es. COCO).

Risultati. CIDEr aggiunge informazione vera: *discrimina* dove BLEU appiattisce. La media per-attributo ordina i modelli correttamente ($\text{random } 0,23 < \text{freq_w } 0,37 < \text{m1 } 0,59 < \text{m3 } 0,65 < \text{m6 } 0,70$): i modelli addestrati battono nettamente le baseline casuali, e m6 è il migliore. `most_frequent` resta in testa ($0,79$) solo perché il riferimento è spesso la frase frequente (Fig. 3).

2.5 BERTScore

Cosa misura. La similarità **semantica** via embedding contestuali (BERT italiano): non le parole esatte, ma i significati. Riportiamo l’F1. Risponde a: “il modello ha capito il **concetto**, anche riformulando?”.

Range e lettura. Per l’italiano tipicamente $[0,7, 1,0]$: lo “zero” pratico è alto. Va letto in modo relativo: $> 0,90$ forte; $0,84\text{--}0,90$ buono; $< 0,83$ distante.

Risultati. Tutti i valori in $0,83\text{--}0,92$: poco discriminante, perché tutte le frasi parlano di formaggio con la stessa struttura. Utile come *sanity check*, non per il ranking. I modelli global scendono a $\approx 0,80$ (ancora i più deboli).

2.6 Conformità Vocabolario (metrica custom)

Cosa misura. La percentuale di parole della caption che appartengono al **vocabolario controllato** del progetto (1278 forme sensoriali attestate). Risponde a una domanda che nessuna metrica standard pone: “il modello «parla formaggio» col registro certificato, o inventa termini?”.

Range e lettura. $[0, 1]$. Il vocabolario contiene solo lemmi sensoriali (non parole funzionali *il/ha/di*), quindi anche una caption perfetta non raggiunge 1,0: leggere in relazione. $> 0,55$ forte; $0,45\text{--}0,55$ moderato; $< 0,45$ fuori registro.

Risultati. Modelli addestrati $\approx 0,48\text{--}0,61$. Più alta sugli attributi descrittivi (Texture $\approx 0,60\text{--}0,67$, Struttura $\approx 0,57$). I modelli global hanno conformità pari o superiore ai per-attributo, pur avendo BLEU/METEOR peggiori: frasi più “lessicalmente corrette” ma meno fedeli al riferimento specifico.

2.7 CLIPScore (la più importante per il captioning)

Cosa misura. L’unica metrica che guarda l’immagine. Proietta immagine e caption nello stesso spazio CLIP (versione multilingue per l’italiano) e ne calcola la similarità coseno:

$$\text{CLIPScore} = \cos(\text{CLIP}_{\text{img}}(\text{fetta}), \text{CLIP}_{\text{txt}}(\text{caption})).$$

Ignora il riferimento del panelista. Risponde alla domanda più onesta: “questa caption descrive bene *questa immagine*?”. Aggira il problema del riferimento singolo.

Range e lettura. Per CLIP multilingue la coseno grezza è bassa in assoluto ($\approx 0,15\text{--}0,30$ anche per coppie corrette): **non è una percentuale**. Conta il confronto relativo e la direzione. Sul nostro setup: $\approx 0,20\text{--}0,21$ attributo ben descrivibile; $\approx 0,18$ poco legato all’aspetto visivo.

Risultati. Due esiti chiave, discussi nella sezione seguente.

3 Risultati trasversali




Figura 1: CLIPScore medio sui 7 attributi per-attributo. Gli scarti tra modelli addestrati e baseline costante sono dentro il rumore ($< 0,004$).

3.1 CLIPScore: i modelli addestrati non battono la baseline costante

La media CLIPScore è quasi identica per tutti (Tab. 1): i modelli addestrati (m1/m3/m6) *non* superano `most_frequent`, che spara sempre la stessa frase ignorando l’immagine. **Interpretazione:** con l’encoder congelato i modelli non ancorano la caption ai contenuti visivi — fanno *language modeling* sulla distribuzione delle caption. È la conferma quantitativa e indipendente del risultato dello *shuffle test*: se i modelli usassero l’immagine, batterebbero la baseline costante. Non lo fanno.

Tabella 1: Metriche medie per modello (7 attributi per-attributo). CIDEr ordina i modelli; CLIPScore resta piatto.

Modello	BLEU-4	CIDEr	Vocab	CLIPScore
most_frequent (costante)	0,362	0,790	0,524	0,1902
freq_weighted	0,362	0,370	0,529	0,1919
random	0,358	0,234	0,527	0,1913
m1_cnn_lstm	0,384	0,586	0,535	0,1925
m3_vit_transformer	0,392	0,646	0,532	0,1921
m6_vit_gpt	0,398	0,704	0,538	0,1933

3.2 CLIPScore distingue attributi visibili da non visibili

La variazione vera è **per attributo**, non per modello. CLIP “vede” che texture (0,208), colore (0,206) e struttura (0,197) sono descrivibili dall’immagine, mentre aroma (0,181), sapore (0,184) e profumo (0,185) restano bassi: nessuna immagine può rivelare un sapore. È un controllo di sanità che *valida* il comportamento della metrica. Eccezione istruttiva: **Spessore della Crosta** è fisicamente visibile ma basso (0,184), perché la crosta è una porzione piccola della fetta e CLIP la pesa poco.




Figura 2: CLIPScore medio per attributo. Gli attributi visivi (texture, colore, struttura) ottengono valori più alti; olfatto/gusto restano bassi per chiunque.




Figura 3: CIDEr per attributo. A differenza di BLEU-4 (valori vicini fra i modelli), CIDEr separa i modelli e premia i termini sensoriali rari azzeccati.

3.3 CIDEr discrimina dove BLEU appiattisce

Su *Spessore della Crosta*, BLEU-4 dà 0,39–0,44 per tutti, mentre CIDEr va da 1,04 (freq_weighted) a 2,29 (most_frequent), con i modelli addestrati in mezzo (1,55–1,76): un ordinamento che BLEU non vedeva.

3.4 Il tranello di BLEU, visualizzato

`most_frequent` ha il BLEU-1 più alto (caption costante che combacia sul prefisso) ma CLIPScore identico a tutti. Una metrica da sola può mentire: serve leggerle insieme.

3.5 Profilo completo di un modello




Figura 4: Stessa coppia di modelli (*most_frequent* vs *m6*) vista da due metriche. A sinistra BLEU-1: la caption costante *vince*. A destra CLIPScore: i due sono praticamente uguali. BLEU-1 da solo è fuorviante.

4 Come riprodurre

Ambiente isolato in `eval_metrics/.venv` (non tocca le dipendenze del training).

1. `.\eval_metrics\setup.ps1` — crea il venv e installa le dipendenze (una tantum).
2. `python eval_metrics\add_image_paths.py` — aggiunge `image_path` ai `predictions.csv` (per CLIPScore).
3. `python eval_metrics\compute_metrics.py predictions --images-root .` — calcola tutte le metriche; scrive `metrics_summary.csv`.

Tabella 2: Implementazione delle metriche.

Metrica	Libreria / metodo	Tipo
BLEU-1/4, METEOR, ROUGE-L	HuggingFace <code>evaluate</code>	testuale, 1 rif.
CIDEr	implementazione standalone (TF-IDF n -gram)	testuale, 1 rif.
BERTScore-F	<code>bert-score</code> , <code>lang="it"</code>	semantica
Conformità Vocabolario	custom su <code>vocabulary.csv</code>	dominio
CLIPScore	<code>open_clip</code> , <code>xlm-roberta-base-ViT-B-32</code> (LAION-5B)	image-grounded

5 Limiti e caveat

- **Riferimento singolo:** tutte le metriche testuali confrontano contro una sola caption; CIDEr e BLEU ne soffrono strutturalmente. CLIPScore (che ignora il riferimento) è il complemento più prezioso.
- **CIDEr** qui è a un riferimento: confrontabile fra i nostri modelli, non con benchmark esterni.
- **BERTScore** è poco discriminante su questo dominio (frasi simili).




Figura 5: Profilo di m6 (ViT+GePpeTto) per attributo: valori grezzi annotati, colore normalizzato per colonna (rende comparabili scale diverse). Si nota la correlazione tra CIDEr alto e gli attributi a caption dominante (Spessore), e la relativa uniformità di CLIP.

- **CLIPScore** usa CLIP generico (non fine-tuned sul formaggio): coglie tratti grossolani (colore, texture), non sfumature sensoriali fini; i valori assoluti bassi sono normali.
- **CLIPScore costante tra modelli** è esso stesso il risultato: il collo di bottiglia è l'**encoder congelato**. Il prossimo esperimento naturale è il **fine-tuning dell'encoder** e la ri-misura di CLIPScore: se i modelli si staccano dalla baseline, l'immagine viene finalmente sfruttata.

A Tabella completa per attributo

Tabella 3: BLEU-4 / CIDEr / CLIPScore per attributo, modelli addestrati vs `most_frequent`. Dati da `metrics_summary.csv`.

Attributo	BLEU-4			CIDEr			CLIPScore		
	m3	m6	m.f.	m3	m6	m.f.	m3	m6	m.f.
Aroma	0,45	0,45	0,44	0,53	0,62	0,53	0,182	0,183	0,178
Profumo	0,38	0,38	0,32	0,35	0,39	0,33	0,183	0,186	0,187
Sapore	0,41	0,42	0,40	0,53	0,61	0,86	0,184	0,184	0,181
Texture	0,34	0,35	0,29	0,34	0,42	0,42	0,208	0,210	0,204
Spessore	0,40	0,42	0,44	1,55	1,76	2,29	0,184	0,185	0,184
Struttura	0,31	0,33	0,21	0,41	0,41	0,52	0,198	0,199	0,193
Colore	0,45	0,44	0,42	0,81	0,73	0,59	0,205	0,207	0,205

m.f. = `most_frequent`. La tabella completa con tutte le 8 metriche per tutti i 43 file è in `eval_metrics/metrics_summary.csv`.